Checkpoint 5

Statistical Computing with R and Python | Parte 1

Integrantes

Nome completo	RM
Luigi Francisco	571204
Breno Filipe	571824
Igor Cypriano	570353
Diogo Lopes	570732

Objetivo e dados

Análise exploratória de 178 vinhos, com foco em duas variáveis quantitativas: álcool e ácido málico. O arquivo **wine.csv** acompanha o código, permitindo reproduzir os resultados sem conexão com a internet.

Fonte: https://gist.github.com/tijptjik/9408623

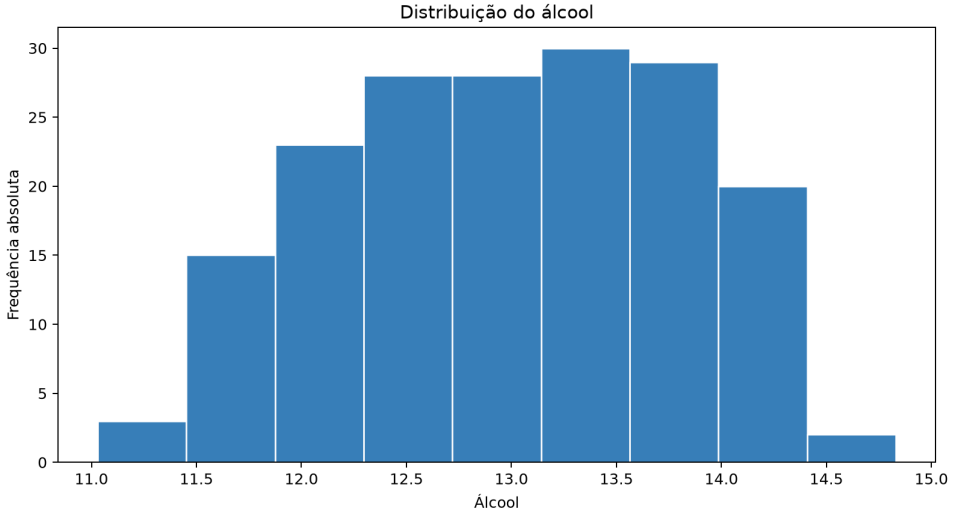
Síntese dos resultados

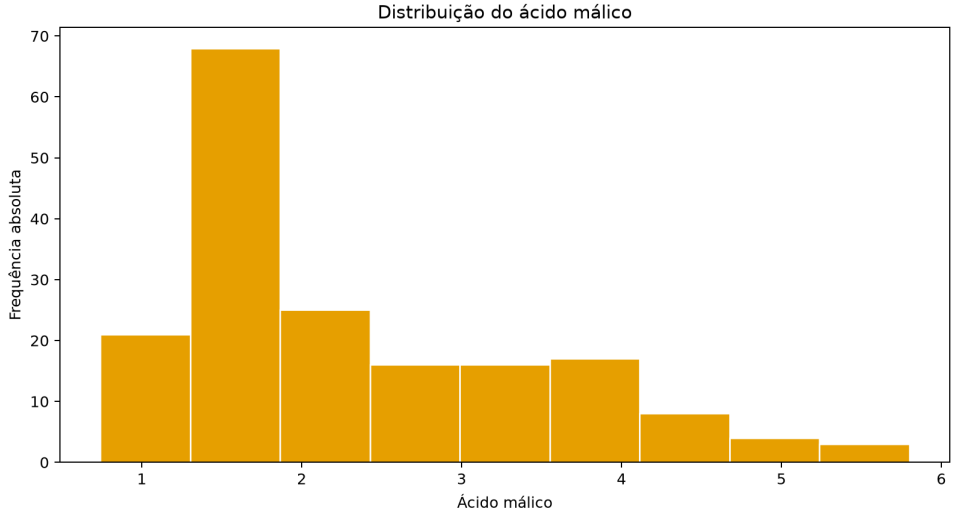
Variável	Centro e dispersão	Formato e modelo probabilístico
Álcool	Média 13,00; mediana 13,05; CV 6,24%.	Quase simétrico. Normal útil como aproximação nos eventos estudados.
Ácido málico	Média 2,34; mediana 1,87; CV 47,82%.	Assimétrico à direita. Probabilidades calculadas empiricamente.

As seções seguintes apresentam as tabelas, os gráficos, as medidas descritivas e dois cálculos probabilísticos para cada variável.

a) Distribuição de frequências

As duas variáveis foram divididas em nove classes pela regra de Sturges. No álcool, as frequências se concentram no centro; no ácido málico, a segunda classe contém 68 vinhos (38,20%) e a distribuição tem cauda à direita.





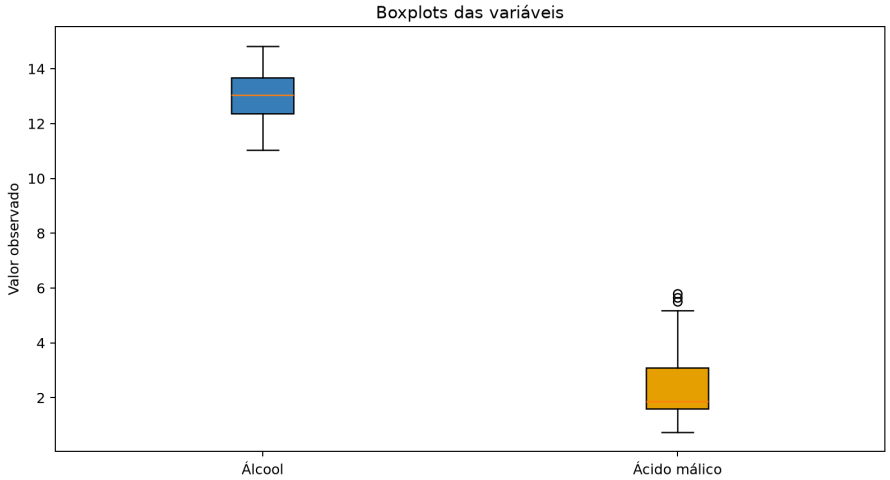
Intervalo	fi	fr %	Fi	Fr %
(11.026, 11.452]	3	1.69	3	1.69
(11.452, 11.874]	15	8.43	18	10.11
(11.874, 12.297]	23	12.92	41	23.03
(12.297, 12.719]	28	15.73	69	38.76
(12.719, 13.141]	28	15.73	97	54.49
(13.141, 13.563]	30	16.85	127	71.35
(13.563, 13.986]	29	16.29	156	87.64
(13.986, 14.408]	20	11.24	176	98.88
(14.408, 14.83]	2	1.12	178	100.00

Intervalo	fi	fr %	Fi	Fr %
(0.735, 1.302]	21	11.80	21	11.80
(1.302, 1.864]	68	38.20	89	50.00
(1.864, 2.427]	25	14.04	114	64.04
(2.427, 2.989]	16	8.99	130	73.03
(2.989, 3.551]	16	8.99	146	82.02
(3.551, 4.113]	17	9.55	163	91.57
(4.113, 4.676]	8	4.49	171	96.07
(4.676, 5.238]	4	2.25	175	98.31
(5.238, 5.8]	3	1.69	178	100.00

b) Análise descritiva

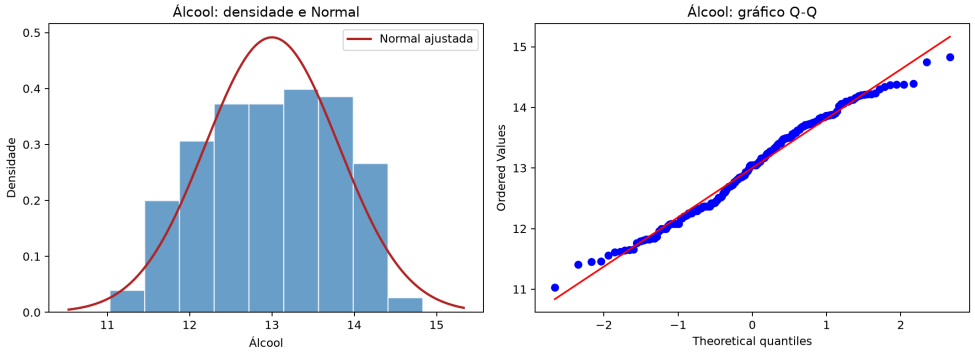
A média e a mediana do álcool são próximas, e o coeficiente de variação é baixo. No ácido málico, a média maior que a mediana e a distância entre os quartis confirmam a assimetria à direita. Pelo critério de 1,5 vezes a amplitude interquartil, há três valores altos discrepantes no ácido málico.

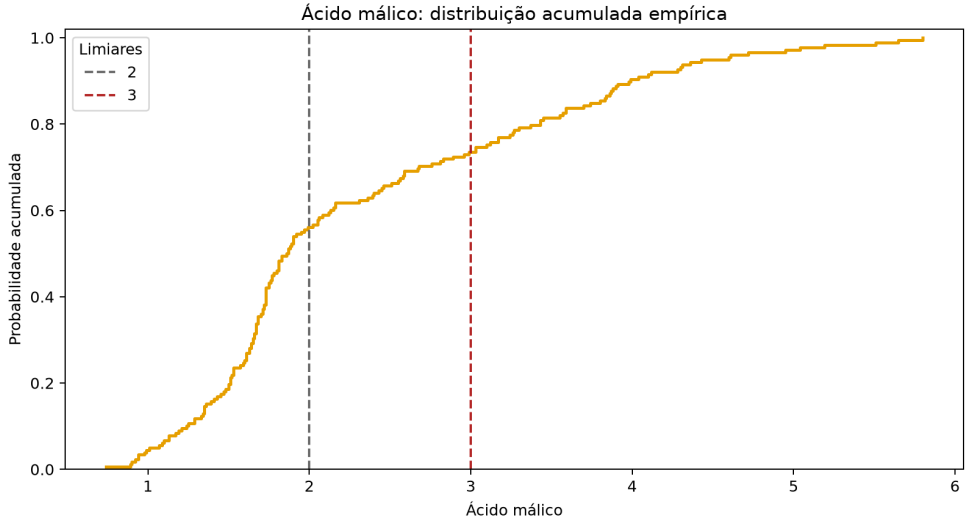
Medida	Álcool	Ácido málico
Média	13,00	2,34
Mediana	13,05	1,87
Moda	12,37 e 13,05	1,73
Mínimo / máximo	11,03 / 14,83	0,74 / 5,80
Amplitude	3,80	5,06
Variância amostral	0,659	1,248
Desvio padrão amostral	0,812	1,117
Coeficiente de variação	6,24%	47,82%
Q1 / Q2 / Q3	12,36 / 13,05 / 13,68	1,60 / 1,87 / 3,08
Amplitude interquartil	1,315	1,480
Assimetria	-0,051	1,040



c) Análise probabilística

Para o álcool, comparamos a Normal ajustada à distribuição observada. Para o ácido málico, usamos a distribuição acumulada empírica, já que a forma dos dados é claramente assimétrica.





Evento	Distribuição utilizada	Probabilidade	Frequência observada
Álcool > 14	Normal ajustada	10,92%	12,36% (22/178)
12 < álcool < 14	Normal ajustada	78,20%	75,28% (134/178)
Ácido málico > 3	Empírica	26,40%	47/178
Ácido málico < 2	Empírica	56,18%	100/178

Interpretação. O teste de Shapiro-Wilk rejeita normalidade estrita para ambas as variáveis (p = 0,0200 para álcool; p < 0,001 para ácido málico). Mesmo assim, a Normal aproxima bem os dois eventos escolhidos para o álcool. Para o ácido málico, as frequências observadas oferecem uma referência direta, sem supor uma forma Normal.

Código, CSV, tabelas e gráficos estão incluídos na pasta desta entrega.